

ESCUELA COLOMBIANA DE INGENIERÍA JULIO GARAVITO
DECANATURA DE INGENIERÍA DE SISTEMAS

PTIA – PRINCIPIOS Y TECNOLOGÍAS – INTELIGENCIA ARTIFICIAL

STUDYFLOW AI: GENERADOR INTELIGENTE Y ADAPTATIVO DE HORARIOS DE ESTUDIO

PROYECTO PTIA

GRUPO III

INTEGRANTES:

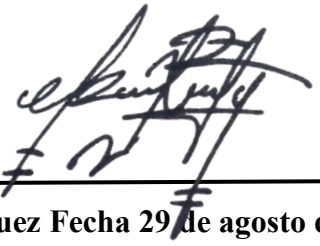
JUAN DAVID MORENO D'ALEMAN
KAROL XIMENA RODRIGUEZ REYES

FECHA DE ENTREGA
12 – 10 – 2026
BOGOTÁ 2026-2

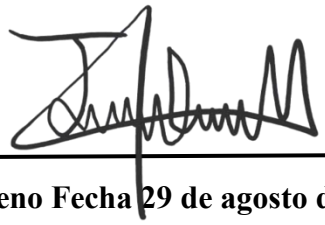
DECLARACIÓN FIRMADA

"Declaro que he escrito este trabajo de investigación por mí mismo, y que no he utilizado otras fuentes o recursos que los indicados para su preparación. Declaro que he indicado claramente todas las citas directas e indirectas, y que este documento no se ha presentado en otro lugar para fines de examen o publicación"

Nombre del estudiante & Firma:



Karol Rodriguez Fecha 29 de agosto de 2026



Juan Moreno Fecha 29 de agosto de 2026

INTRODUCCIÓN 4

1. ¿Cuáles serían tres problemas que les interesa resolver? 4

A. Planificación inteligente del tiempo de estudio 4

B. Priorización de actividades académicas 4

C. Adaptación de planes de estudio ante cambios 4

2. ¿Por qué como proyecto de PTIA? 5

TRABAJOS RELACIONADOS 5

A. ¿Cuáles son dos trabajos relacionados a cada problema? 5

- **Planificación inteligente del tiempo de estudio** 5
- **Priorización de actividades académicas** 6
- **Adaptación de planes de estudio** 6

B. ¿Cuáles criterios van a usar para seleccionar el problema a resolver? 6

C. ¿Cuál es el problema seleccionado? 7

JUSTIFICACIÓN 7

A. ¿Cuál es el gran problema que se quiere resolver? 7

B. ¿Por qué es importante resolverlo? 8

ALCANCE Y OBJETIVOS 8

A. ALCANCE Y OBJETIVOS 8

PROTOTIPO INICIAL 8

A. LINK DE FLUJO 8

B. LOGO 9

C. DISEÑO INICIAL 9

D. VIDEO 10

INTRODUCCIÓN

Hoy en día, la organización del tiempo es una dificultad frecuente para los estudiantes, sobre todo cuando su atención debe dividirse simultáneamente entre clases, trabajos, evaluaciones, proyectos y actividades personales. La planificación manual resulta poco eficiente cuando hay que considerar muchas fechas de entrega, distintos niveles de dificultad y una disponibilidad de tiempo limitada.

Además, un horario que inicialmente era adecuado puede dejar de serlo con el tiempo: el estudiante no logra cumplir una sesión, enfrenta imprevistos personales, incumple una entrega, aparece una actividad nueva o cambia la fecha de un trabajo.

Bajo esta idea, las técnicas de inteligencia artificial permiten desarrollar herramientas capaces de interpretar información académica expresada en lenguaje natural y usarla para apoyar la planificación del tiempo de estudio.

El proyecto busca aprovechar estas capacidades para construir una solución que analice las características de las actividades académicas y produzca un plan de estudio personalizado y adaptable.

A. ¿Cuáles serían tres problemas que les interesa resolver?

Para este proyecto se busca resolver tres problemas importantes:

1. Planificación inteligente del tiempo de estudio

Los estudiantes deben distribuir su tiempo entre diferentes actividades académicas, que pueden tener fechas límite, dificultades y prioridades distintas. La elaboración manual de un horario puede generar una distribución desequilibrada del esfuerzo, con exceso de carga en unos periodos y poca en otros.
Se propone desarrollar un sistema que interprete la información académica del estudiante, identifique las actividades relevantes y genere un horario de estudio considerando fechas, prioridades, dificultad de la actividad y la disponibilidad de tiempo.

2. Priorización de actividades académicas

Con muchas actividades y evaluaciones pendientes, es difícil determinar qué actividades deben recibir atención primero. Esta decisión depende de varios factores: la fecha límite, la dificultad, la importancia y el tiempo de desarrollo.

Se propone una solución que analice las características de las actividades y establezca una prioridad para organizar el tiempo disponible.

3. Adaptación de planes de estudio ante cambios

Un horario de estudio puede dejar de ser adecuado cuando no se cumple una sesión programada, aparece una nueva actividad o se modifican fechas. En estos casos, reorganizar todas las actividades puede generar nuevos conflictos de tiempo o concentrar muchas actividades cerca de sus fechas límite. Se propone una solución que sea capaz de detectar cambio en el estado de las actividades y reorganizar las sesiones y actividades restantes de acuerdo con esas nuevas condiciones

B. ¿Por qué como proyecto de PTIA?

Estos problemas ofrecen oportunidades para aplicar técnicas de IA en situaciones de planificación y toma de decisiones. El primero es el que permite integrar los otros dos, ya que planificar el estudio requiere determinar la importancia de cada actividad y distribuirla en el tiempo disponible, considerando condiciones futuras.

Es un proyecto adecuado para PTIA porque combina un modelo de lenguaje (LLM), una red neuronal (Perceptrón Multicapa o MLP) y un algoritmo de asignación determinista. En lugar de depender del LLM para tomar decisiones de horario (lo que podría generar datos inventados), este actuará exclusivamente como traductor que convierte las instrucciones del estudiante en datos estructurados (JSON validado).

Posteriormente, el MLP evaluará la prioridad y el perfil de reparto del trabajo de cada actividad, mientras que una capa determinista asignará los bloques de tiempo. Así se separa el procesamiento del lenguaje de las decisiones de asignación en el tiempo.

TRABAJOS RELACIONADOS

Para evaluar la viabilidad de los problemas planteados, se revisaron soluciones y trabajos relacionados que muestran cómo se han abordado la planificación académica, la priorización de actividades y la generación de horarios mediante diversas técnicas.

A. ¿Cuáles son dos trabajos relacionados a cada problema?

- **Planificación inteligente del tiempo de estudio**
  Smart Study Planner – AI-Based Personalized Time Management.

  Propone un sistema que genera horarios personalizados considerando dificultad, fechas límite, disponibilidad y preferencias del estudiante. También permite reprogramar actividades no completadas. Utiliza inteligencia artificial y machine learning.

  Fuentes: *https://rjwave.org/ijedr/viewpaperforall.php?paper=IJEDR2601268*

  AI Personal Study Buddy.

  Desarrolla una aplicación web que genera horarios de estudio considerando fechas límite y tiempo

disponible. Incluye funcionalidades adicionales como resúmenes y cuestionarios. Utiliza inteligencia artificial para personalizar el apoyo académico.

Fuentes: *https://www.ijsdr.org/viewpaperforall.php?paper=IJSDR2504417*

- **Priorización de actividades académicas**
  AI-Based Smart Study Planner.

  Propone priorizar actividades según criterios como urgencia e importancia para generar recomendaciones de estudio. Utiliza inteligencia artificial, reglas y técnicas de machine learning.

  Fuentes: *https://www.ijset.in/ai-based-smart-study-planner/*

  StudySmart – AI-Powered Study Planner.

  Considera factores como fechas de exámenes, carga académica y nivel de confianza del estudiante para determinar qué actividades requieren mayor atención. Utiliza un enfoque basado en IA y análisis de datos.

  Fuentes: *https://github.com/KanannSharmaa25/StudySmart-AI-Planner/*

- **Adaptación de planes de estudio**
  Smart Study Planner – Academic Stress Reduction and Student Learning Outcomes Improvement.

  Propone planes de estudio personalizados que pueden adaptarse según los hábitos y desempeño del estudiante. Utiliza machine learning y análisis del aprendizaje.

  Fuentes: *https://zenodo.org/records/20052967*

  Personalized Student AI Scheduling Assistant.

  Desarrolla un asistente capaz de generar horarios dinámicos y adaptarlos a las necesidades del estudiante. Utiliza inteligencia artificial, reinforcement learning y servicios como ChatGPT y Google Calendar.

  Fuentes: *https://goldncloudpublications.com/index.php/irjaem/article/view/823*

B. ¿Cuáles criterios van a usar para seleccionar el problema a resolver?

Para seleccionar el problema que será desarrollado durante el proyecto se consideran los siguientes criterios:

- ✓ **Relevancia:** el problema debe representar una dificultad real y tener una aplicación práctica.
- ✓ **Uso significativo de inteligencia artificial:** la solución debe requerir capacidades de interpretación, clasificación o toma de decisiones que justifiquen el uso de IA.

- ✓ **Viabilidad técnica:** la solución debe poder implementarse con los recursos, conocimientos y tiempo disponibles para el proyecto.
- ✓ **Capacidad de evaluación:** debe ser posible definir casos de prueba que permitan comparar las entradas proporcionadas al sistema con los resultados esperados y obtenidos.
- ✓ **Capacidad de adaptación:** se considera favorable que la solución pueda responder a cambios en las condiciones iniciales.
- ✓ **Alcance controlado:** el problema debe poder simplificarse de manera que sea posible construir una prueba de concepto funcional dentro del periodo del curso.

C.¿Cuál es el problema seleccionado?

Después de considerar los criterios anteriores, se selecciona el problema de *planificación inteligente del tiempo de estudio*, debido a que permite integrar las capacidades de priorización y adaptación identificadas en los otros dos problemas.

La solución propuesta será un Generador Inteligente y Adaptativo de Horarios de Estudio, cuyo propósito será transformar información académica proporcionada por el estudiante en un plan de estudio personalizado.

El sistema recibirá, mediante un formulario complementado con instrucciones en lenguaje natural: el nombre de cada actividad, su prioridad (alta, media o baja), su dificultad (alta, media o baja), su fecha límite, el tiempo que el estudiante estima dedicarle y la disponibilidad horaria del estudiante

A partir de esta información, el sistema utilizará un modelo de inteligencia artificial para identificar y estructurar las actividades académicas. Posteriormente, se utilizará dicha información para establecer una distribución de sesiones de estudio.
El proceso general será:

1. Entrada del estudiante (formulario y/o texto).
2. Traducción a datos estructurados con el LLM.
3. Validación de factibilidad.
4. Evaluación con el MLP (prioridad y reparto).
5. Asignación determinista de sesiones.
6. Presentación del horario y adaptación ante cambios.

JUSTIFICACIÓN

A. ¿Cuál es el gran problema que se quiere resolver?

El problema central es la dificultad de construir y mantener una planificación de estudio que tenga en cuenta simultáneamente las actividades académicas, sus fechas límite, su dificultad, su prioridad y el tiempo realmente disponible del estudiante.

Una planificación manual puede ser suficiente cuando existe una cantidad pequeña de actividades, pero puede volverse difícil de mantener cuando aumentan las evaluaciones y entregas o cuando se presentan cambios durante el periodo académico.

El proyecto busca abordar esta dificultad mediante una solución que automatice parte del proceso de análisis y planificación. Para ello, se utilizará un modelo de lenguaje (LLM) como un puente traductor que convierte la información académica del estudiante en un formato de datos estructurado.

Una vez estructurada la información, un Perceptrón Multicapa (MLP) evaluará las características de cada actividad para decidir su prioridad y cómo debe distribuirse el trabajo en el tiempo, asegurando junto con una capa de asignación determinista y validadores de factibilidad que el horario final cumpla con las restricciones de disponibilidad del estudiante.

B. ¿Por qué es importante resolverlo?

Una planificación adecuada puede ayudar al estudiante a distribuir sus sesiones de estudio de manera más organizada y evitar que todas las actividades se concentren cerca de sus fechas límite.

La importancia de la solución no se limita a generar un horario inicial. Una característica fundamental será la posibilidad de adaptarlo cuando las condiciones cambien. Por ejemplo, si el estudiante no realiza una sesión programada, el sistema podrá considerar dicha situación y reorganizar las sesiones restantes.

Esto permite plantear el proyecto como un problema de planificación dinámica en lugar de limitarlo a la generación estática de un calendario.

ALCANCE Y OBJETIVOS

A. ¿Cuál es el problema que efectivamente van a resolver?

Vamos a resolver la generación y adaptación de horarios de estudio personalizados a partir de los datos académicos de un estudiante (actividades, dificultad, tiempos y fechas límite). La solución integra un modelo de lenguaje (LLM), que procesa las entradas en lenguaje natural y las estructura en formato JSON, y un Perceptrón Multicapa (MLP), que evalúa cada actividad para determinar su nivel de prioridad y su perfil de distribución del trabajo a lo largo del tiempo disponible. Finalmente, un algoritmo determinista asigna los bloques de tiempo respetando las restricciones duras.

Para el Hito 2 se implementa y evalúa el componente central de la solución, el MLP, junto con su dataset sintético de entrenamiento. El LLM traductor, la capa de asignación completa y la interfaz funcional se desarrollan en el Hito 3.

B. ¿Por qué consideran que es una simplificación adecuada?

El proyecto se limita a un estudiante, un periodo académico y una entrada estructurada mediante un formulario complementado con instrucciones en lenguaje natural, sin integración con calendarios externos ni con plataformas académicas. Se considera una simplificación adecuada porque conserva los elementos que definen el problema (fechas límite, prioridad, dificultad, disponibilidad limitada y necesidad de reorganizar ante cambios) y deja fuera aspectos que aportan complejidad de integración, no de decisión.

A nivel de diseño, la simplificación se apoya en dos decisiones. Primero, el MLP evalúa una actividad a la vez con un vector de entrada de tamaño fijo, lo que evita modelar el problema completo como una optimización combinatoria. Segundo, las reglas duras (disponibilidad y fechas) se delegan a una capa determinista que las respeta por construcción. Cuando una actividad no cabe, el sistema no la fuerza: la reporta como no asignada, de modo que el estudiante conoce las limitaciones del plan. En el Hito 2, además, el MLP se evalúa de forma aislada sobre datos sintéticos, lo que permite validar su comportamiento antes de integrarlo con el resto del sistema. Esto permite demostrar la viabilidad técnica en el periodo del curso sin perder la validez del problema.

C. ¿Cuál sería el objetivo (cuantitativo y cualitativo)? Detallar objetivo general

- **Objetivo general.** Desarrollar una prueba de concepto funcional (MVP) de un generador de horarios de estudio adaptativo que utilice un LLM para traducir la entrada del estudiante a datos estructurados y un MLP multitarea para determinar la prioridad y el reparto del trabajo, garantizando mediante una capa de asignación determinista que ninguna sesión viole la disponibilidad o las fechas límite.
- **Objetivos cuantitativos**

  Hito 2 (MLP):

  - Alcanzar una correlación de Spearman ≥ 0.95 entre la prioridad predicha por el MLP y la del profesor heurístico en el conjunto de prueba.
  - Obtener un error absoluto medio ≤ 0.05 por tramo en el perfil de reparto frente a la referencia.
  - Superar, en ambas métricas, a dos líneas base: una distribución uniforme y una regresión lineal.

  Hito 3 (sistema completo):

  - Lograr 0 sesiones fuera de la disponibilidad del estudiante, y que el 100 % de las actividades que no puedan asignarse sean reportadas explícitamente.
  - Reducir la carga máxima diaria en al menos 20 % frente a una línea base de distribución uniforme.
  - Replanificar tras un cambio en menos de 5 segundos.
  - Extraer correctamente al menos 90 % de los campos en 20 instrucciones de prueba, y detectar mediante el validador de salida las inconsistencias entre el texto del LLM y el horario real.

- **Objetivos cualitativos:**

- En el Hito 3, ofrecer una interacción natural en la que el estudiante pida cambios en lenguaje natural (por ejemplo, "mueve la sesión del martes") y el sistema devuelva un horario coherente.
- Evaluar la claridad y utilidad del horario mediante una prueba con 5 estudiantes y una escala de satisfacción de 1 a 5, con meta de promedio ≥ 4.

DISEÑO METODOLÓGICO

A. ¿Cuál es la estrategia general seleccionada para la solución? Justificación

La estrategia seleccionada es un **pipeline híbrido** que combina un modelo de lenguaje (LLM), una red neuronal (MLP) y algoritmos deterministas. El flujo inicia con el LLM, que traduce la entrada del estudiante (formulario o instrucciones en lenguaje natural) a un JSON validado con un esquema estricto. Luego, un validador de factibilidad verifica que la carga de trabajo cabe en el tiempo disponible. Los datos validados pasan al MLP, que predice la prioridad de cada actividad y su perfil de reparto a lo largo del tiempo, y una capa de asignación determinista convierte esas predicciones en sesiones concretas dentro de los bloques libres del estudiante.

Justificación. Esta estrategia asigna a cada componente la tarea que mejor resuelve. El LLM se limita a procesar lenguaje, donde es fuerte, y no toma decisiones de horario, donde puede inventar datos o violar restricciones. Las reglas duras (disponibilidad y fechas límite) quedan en código determinista, que las garantiza. La decisión "difusa" de cuánto priorizar y cómo repartir el esfuerzo la asume el MLP, que a diferencia de una fórmula fija puede reentrenarse. En esta prueba de concepto se entrena con datos sintéticos etiquetados por un "profesor heurístico" basado en reglas pedagógicas; a futuro, podría ajustarse con datos reales de cumplimiento de sesiones, algo que una heurística fija no permite sin reescribir sus reglas.

En el Hito 2 se implementa el MLP junto con su dataset sintético de entrenamiento; los demás componentes se diseñan en este documento y se implementan en el Hito 3.

B. ¿Dónde se concentra la inteligencia de la solución? (conocimiento + razonamiento)

La inteligencia se distribuye en tres componentes, que combinan conocimiento aprendido y razonamiento explícito:

1. **Comprensión del lenguaje (LLM):** interpreta instrucciones del estudiante, como "estoy enfermo hoy, pasa todo a mañana", y las convierte en variables estructuradas. Es conocimiento general del lenguaje, preentrenado.
2. **Conocimiento aprendido (MLP):** aproxima el criterio experto del profesor heurístico para priorizar actividades y distribuir la carga en tres tramos. Este conocimiento se adquiere del dataset sintético etiquetado con reglas pedagógicas.
3. **Razonamiento basado en reglas (capa de asignación y validadores):** verifica la factibilidad, ubica las sesiones respetando las restricciones y comprueba que el texto generado coincida con el horario real. Es razonamiento simbólico explícito y verificable.

La separación permite que cada decisión la tome el componente más confiable para ese tipo de problema.

C. ¿Qué herramienta seleccionaron para implementar la solución? Justificación

- **Python:** lenguaje principal por su ecosistema de IA y por integrar en un mismo entorno el modelo, las validaciones y el planificador.
- **Keras / TensorFlow:** permiten definir y entrenar el MLP multitarea (dos salidas con pérdidas distintas, capa oculta con activación tanh) con poco código, lo que facilita iterar sobre la arquitectura.
- **NumPy, pandas, scikit-learn y Matplotlib:** generación y manejo del dataset sintético, partición de los datos, cálculo de la correlación de Spearman y gráficas de entrenamiento.
- **Pydantic (Hito 3):** define el esquema del JSON y rechaza datos mal formados, para que los errores del LLM no lleguen al modelo.
- **API de LLM, Gemini (Hito 3):** procesa el lenguaje natural de entrada y redacta el horario final. Se eligió porque se considera la opción más sencilla de implementar y de las mejores como intérprete.
- **FastAPI (Hito 3):** expone el modelo y la lógica de planificación como servicios, y conecta el frente en React con el código en Python.
- **TypeScript (React) (Hito 3):** interfaz del prototipo funcional, con componentes reutilizables para formulario, calendario y chat de cambios.
- **Figma y Marvel:** prototipo navegable de la interfaz antes de implementarla, para validar el flujo con usuarios.
- **SQLite (Hito 3):** persistencia ligera de actividades y sesiones, suficiente para una prueba de concepto y sin necesidad de un servidor de base de datos.

D. ¿Cuál es la arquitectura de la solución? (Componentes y relaciones)

La solución se organiza en un frente de usuario, un backend con los componentes de procesamiento y una capa de persistencia. En el Hito 2 se implementa el MLP (componente 4); los demás componentes se desarrollan en el Hito 3. El flujo es el siguiente:

1. **Interfaz (React):** el estudiante ingresa actividades mediante un formulario (nombre, prioridad, dificultad, fecha límite y tiempo estimado) y su disponibilidad, o escribe instrucciones en lenguaje natural.
2. **LLM traductor (Gemini):** convierte la entrada en un JSON validado por Pydantic.
3. **Validador de factibilidad:** comprueba, para cada fecha límite, que las horas estimadas de lo que vence hasta ese momento no superen las horas disponibles (con un margen). Si no es factible, avisa y sugiere qué recortar.
4. **MLP (componente principal):** recibe las características de cada actividad y devuelve prioridad y perfil de reparto mediante una capa oculta de 16 neuronas con activación tanh.
5. **Capa de asignación determinista:** ordena por prioridad, convierte el perfil en horas por día y crea sesiones en los bloques libres; las actividades que no caben se marcan como no asignadas.
6. **Validador de salida y LLM redactor:** comprueba que lo que se va a comunicar coincide con el horario real y lo redacta para el usuario.
7. **Persistencia (SQLite):** guarda actividades, sesiones y su estado de cumplimiento.

8. **Ciclo de adaptación:** cuando el estudiante incumple una sesión, agrega una actividad o pide un cambio, el evento se registra en la base de datos y se reinicia el flujo desde el paso 2 solo con lo pendiente, recalculando las horas restantes de cada actividad.

En el Hito 3, dado que la solución envía a la API del LLM información académica del estudiante, se limita lo transmitido a los campos estrictamente necesarios (nombres de actividades, fechas y tiempos), sin datos personales identificables. Además, la interfaz permite revisar y corregir los datos extraídos antes de generar el horario, y el sistema informa explícitamente cuando una actividad no puede asignarse, para que la decisión final siempre quede en manos del estudiante.

E. ¿Cuál es el componente principal? (Descripción detallada)

El componente principal es un **Perceptrón Multicapa (MLP) con arquitectura multitarea**. Evalúa una actividad a la vez, de modo que su entrada tiene siempre el mismo tamaño sin importar cuántas actividades tenga el estudiante. Cada actividad se representa con un vector de 6 características: días restantes hasta la entrega, prioridad ingresada, dificultad, horas estimadas, horas disponibles en la ventana y carga relativa. Esta última se calcula con el conjunto completo de actividades (horas pendientes totales entre horas disponibles en esa ventana), por lo que aporta el contexto global, aunque cada actividad se procese de forma individual. Las seis características se normalizan al rango [-1, 1], adecuado para la activación tanh.

La red tiene una capa oculta de 16 neuronas con activación tanh, compartida por dos salidas. Se eligió una sola capa porque el problema tiene solo 6 entradas y una relación suave con las salidas, de modo que más profundidad no aportaría capacidad útil y haría más difícil explicar el modelo; tanh, al ser simétrica y acotada, funciona bien con entradas normalizadas en [-1, 1]. En total la red tiene 180 parámetros entrenables (112 en la capa oculta, 17 en la salida A y 51 en la salida B).

- **Salida A (prioridad):** una neurona con activación sigmoide, que devuelve un valor entre 0 y 1 con el nivel de urgencia. Define el orden en que la capa de asignación acomoda las actividades.
- **Salida B (perfil de reparto):** tres neuronas con activación softmax, que devuelven proporciones que suman 1 para el primer, segundo y último tramo de los días disponibles. Por ejemplo, [0.5, 0.3, 0.2] indica adelantar el trabajo.

Dataset sintético. Como no existe un conjunto de datos público de actividades con horarios ideales, se genera un dataset sintético de 3.000 escenarios, cada uno con entre 3 y 8 actividades (Aproximadamente 15.000 casos). Los días restantes varían entre 1 y 30, las horas estimadas entre 1 y 20 y la disponibilidad entre 2 y 8 horas diarias; solo se conservan los escenarios que superan el validador de factibilidad. Cada caso se etiqueta con un profesor heurístico. La prioridad se calcula como 0.40·urgencia + 0.25·prioridad + 0.20·dificultad + 0.15·carga relativa, con urgencia = 1 − días/30, los demás términos en [0, 1] y un ruido gaussiano de desviación 0.02. El perfil de reparto se obtiene calculando s = 0.5·dificultad + 0.3·carga + 0.2·horas (todo en [0, 1]), aplicando softmax a los logits [2.5·s, 0.5, 0], de modo que, a mayor dificultad, carga y horas, más trabajo se adelanta. Los datos se dividen en 70 % entrenamiento, 15 % validación y 15 % prueba, por escenario y no por actividad, para evitar filtración de información entre conjuntos.

Entrenamiento y evaluación: El MLP se entrena mediante aprendizaje supervisado: la salida A se trata como un problema de regresión y la salida B como una clasificación probabilística sobre los tres tramos, con etiquetas generadas por el profesor heurístico (aprendizaje por imitación sobre datos sintéticos).

La función de pérdida combina el error cuadrático medio de la salida A con la entropía cruzada de la salida B, con pesos iguales (1 y 1) ajustables para evitar que una domine a la otra. Se entrena con el optimizador Adam (tasa de aprendizaje 1e-3, lotes de 64), parada temprana sobre la pérdida de validación y semilla fija. Si el entrenamiento conjunto no converge, el diseño permite separarla en dos redes sin modificar el resto del sistema. Dado que el profesor es una función determinista de las entradas, la correlación mide qué tan bien el MLP aproxima la regla, no que la supere; por eso los resultados se comparan con dos líneas base (distribución uniforme y regresión lineal) y, en el Hito 3, con una función de calidad de horario independiente. Adicionalmente, se compara la configuración de 16 neuronas con tanh frente a una con ReLU.

Ejemplo ilustrativo. Para un "Parcial de IA" con 6 días restantes, prioridad alta, dificultad alta y 8 horas estimadas, el modelo entrenado devuelve prioridad **[resultado real]** y perfil de reparto **[resultado real]**. La capa de asignación ubicaría esas horas en los bloques libres, con mayor peso en el tramo que indique el perfil.

PROTOTIPO INICIAL

A. LINK DE FLUJO

https://marvelapp.com/prototype/1d17a5ee

B. LOGO



C. DISEÑO INICIAL



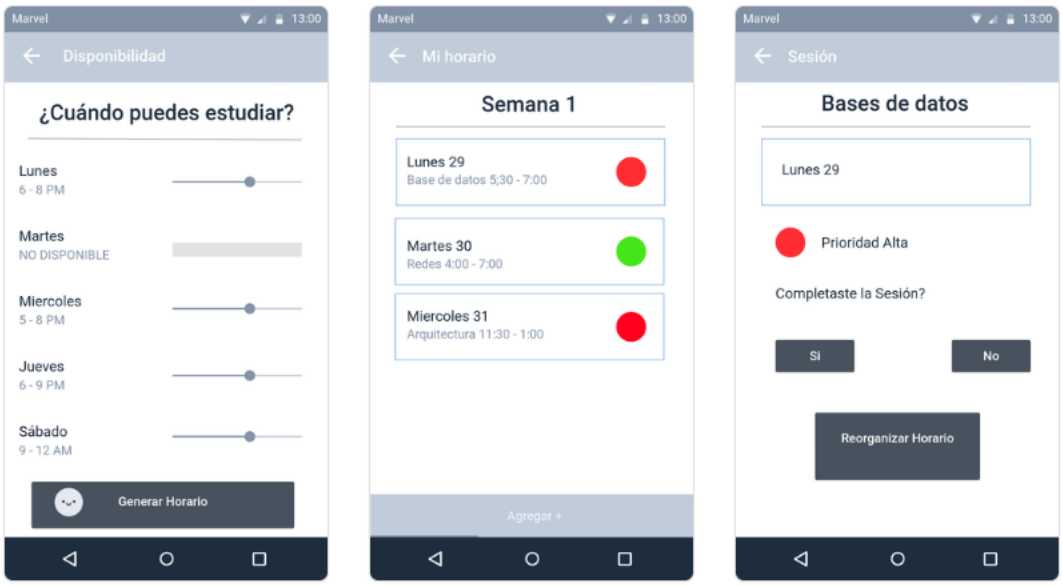












D. VIDEO

https://drive.google.com/file/d/1I1Wq5j9AHK1Eaw50E_-Wlp8wtioYEBvB/view?usp=drivesdk